An Adaptive Sample Processing Hybrid Framework for Stream Classification Under Severe Concept Drift

Anggota Kelompok

1. Bima Jati Kusuma (NRP 6025261006)
2. M. Nasyikh Al Qusyairy (NRP 6025261008)
3. Firmansyah Achmad Adam (NRP 6025261018)
4. Ida Bagus Ari Widhiana (NRP 6025261021)

Institut Teknologi Sepuluh Nopember, Surabaya - Indonesia

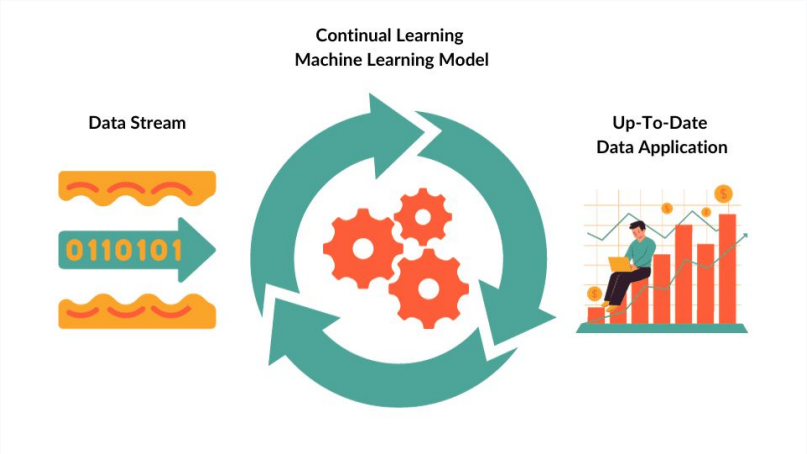
Introduction

Continuous Learning merupakan sebuah pendekatan yang memungkinkan model terus memperbarui pengetahuannya dari data baru sambil mempertahankan pengetahuan lama yang masih relevan.

penyimpanan data historis (pengetahuan lama) dapat meningkatkan kebutuhan memori dan biaya komputasi.

Pada data stream, pola data dapat berubah sehingga model perlu beradaptasi agar prediksinya tetap akurat.

Perubahan pola data ini yang biasa disebut sebagai **data drift**.

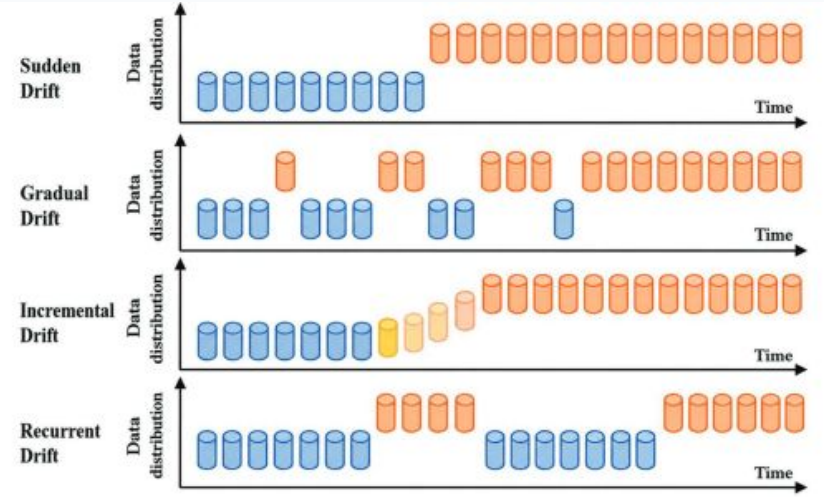


Data Drift Problem

Data Drift merupakan perubahan karakteristik atau pola data dari waktu ke waktu.

Perubahan pola data dapat membuat pengetahuan lama model tidak lagi sesuai, sehingga ketepatan dalam prediksi menurun (Aguiar & Cano, 2024).

- **Sudden (Abrupt) Drift:** Pola lama langsung digantikan pola baru dalam waktu singkat.
- **Gradual Drift:** Pola lama dan pola baru muncul bergantian selama masa transisi. Seiring waktu, pola baru semakin sering muncul hingga menggantikan pola lama.
- **Incremental Drift:** Pola berubah sedikit demi sedikit melalui kondisi-kondisi perantara sampai menjadi pola baru.
- **Recurrent Drift:** Pola yang pernah muncul sebelumnya kembali lagi setelah sempat digantikan pola lain.



Fenomena *Severe Concept Drift*
perubahan distribusi data berlangsung secara mendadak dan berskala global pada banyak kelas sekaligus, memicu penurunan kinerja model secara katastropik

A comprehensive analysis of concept drift locality in data streams

Tujuan: Mengevaluasi pengaruh locality dan magnitude concept drift terhadap kinerja drift detector dan classifier serta menyediakan benchmark yang terstandarisasi.

Gap: Belum tersedia benchmark yang mempertimbangkan locality drift. Penelitian sebelumnya umumnya terbatas pada klasifikasi biner, hanya membandingkan sebagian detector, dan belum mengkaji pemulihan kinerja classifier.

Kontribusi: Mengusulkan empat kategori drift, yaitu single-class local, single-class global, multi-class local, dan multi-class global. Penelitian ini juga menyediakan 2.760 benchmark serta membandingkan sembilan drift detector.

Tahapan & Metode: Data stream dibangkitkan menggunakan Random RBF dan Random Tree dengan variasi kelas, fitur, dan kecepatan drift. Sembilan detector diuji menggunakan Hoeffding Tree dan dievaluasi berdasarkan precision, recall, F1-score, serta detection delay. Strategi adaptasi classifier juga dibandingkan antara Hoeffding Tree, retraining penuh, dan Adaptive Hoeffding Tree.

Hasil: Locality dan jumlah kelas yang terdampak memengaruhi kinerja detector dan classifier. Drift global lebih mudah dideteksi daripada drift lokal. ADWIN dan Page-Hinkley paling seimbang, sedangkan Adaptive Hoeffding Tree meningkatkan akurasi rata-rata sebesar 4,03%.

A comprehensive analysis of concept drift locality in data streams

Kode dan Generator: gabrieljaguiar/locality-concept-drift

Hasil lengkap dalam format csv: 2023 Data Streams Concept Drift Locality - Google Drive

Visualisasi hasil interaktif: A comprehensive analysis of concept drift locality in data streams

Paper: [2311.06396] A comprehensive analysis of concept drift locality in data streams

Anticipating to Change: A Proactive Approach for Concept Drift Adaptation in Data Streams

Masalah:

Tujuan: Mengembangkan pendekatan adaptasi concept drift yang proaktif, yaitu menyesuaikan classifier sebelum perubahan distribusi menyebabkan penurunan performa.

Dataset:

Tahapan & Metode: Mengembangkan empat strategi proaktif pada VFDT, mengujinya pada beberapa skenario perubahan pola data sintetis, lalu membandingkan akurasinya dengan model reaktif. Evaluasi dilakukan dengan memprediksi data terlebih dahulu sebelum menggunakannya untuk melatih model.

Anticipating to Change: A Proactive Approach for Concept Drift Adaptation in Data Streams

Gap Penelitian: Model hanya beradaptasi setelah drift terdeteksi atau setelah performa menurun yang mengakibatkan model menggunakan pengetahuan lama dan mengalami penurunan akurasi.

Kontribusi Penelitian: Menjelaskan perbedaan adaptasi reaktif dan proaktif, serta mengembangkan empat strategi proaktif berbasis Very Fast Decision Tree (VFDT).

Hasil Penelitian & Kesimpulan: Pendekatan proaktif membantu mengurangi penurunan akurasi akibat drift, terutama ketika perubahan berlangsung sedikit demi sedikit.

(TAMBAHKAN CONTRIBUTE terkait metrik)
Recovery Time (RT), **Percentage of Degradation Episodes (PDE)**, dan **Fraction of Time in Degradation (FTDE)**.

DACD: a dynamic adaptive concept drift learning method for streaming data

Masalah:

Tujuan Penelitian: Mengembangkan model yang mampu mendeteksi perubahan pola data dan menyesuaikan neural network agar prediksinya tetap akurat.

Dataset:

Tahapan & Metode: Memantau perubahan pola data menggunakan CUSUM, memilih dan menambah sampel yang diperlukan, lalu memperbarui neural network sesuai perubahan yang terdeteksi. Pengujian dilakukan pada data simulasi dan data nyata dengan mengukur akurasi selama data diproses serta menguji pengaruh pengaturan parameter.

DACD: a dynamic adaptive concept drift learning method for streaming data

Gap Penelitian: Metode sebelumnya belum sepenuhnya menggabungkan deteksi perubahan pola, pemilihan data latih, dan penyesuaian proses pembelajaran dalam satu sistem.

Kontribusi Penelitian: Mengusulkan DACD (Dynamic Adaptive Concept Drift), yaitu framework yang menggabungkan deteksi drift berbasis window CUSUM, neural network adaptif, dan pengolahan sampel untuk menjaga performa model.

Hasil & Kesimpulan Penelitian: DACD menunjukkan kemampuan mempertahankan akurasi dan menyesuaikan pembelajaran ketika pola data berubah pada dataset yang diuji.

A Broad Ensemble Learning System for Drifting Stream Classification

Masalah:

Pendekatan chunk-based lambat merespon *concept drift* dalam blok data, sedangkan *online learning* lambat di awal, tidak stabil dan boros komputasi

Tujuan Penelitian:

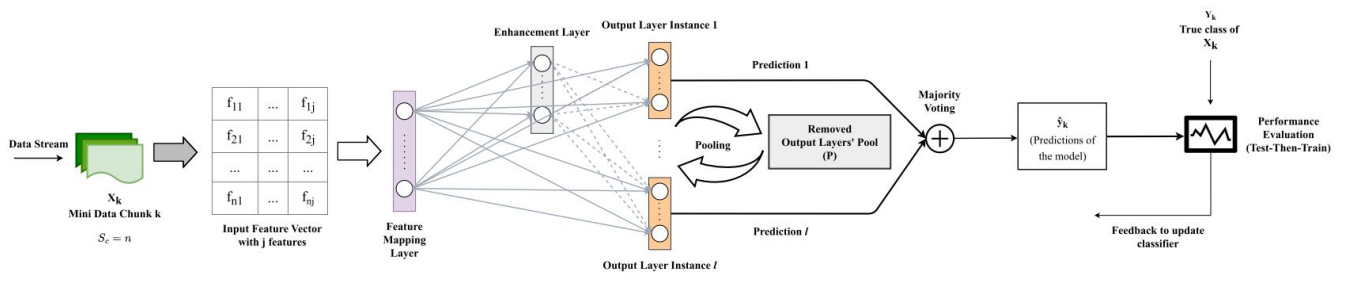
Pengembangan arsitektur *Broad Ensemble Learning System* (BELS) berbasis *lightweight neural network* untuk klasifikasi *data stream* terhadap berbagai jenis *concept drift*.

Dataset:

35 dataset (9 riil, 26 sintetis) yang mencakup 4 tipe drift dan skenario data tidak seimbang (*imbalanced*)

Tahapan Penelitian & Metode:

- Siklus Stream Evaluation
- Pemrosesan Mini-Chunk
- Mekanisme Passive Ensemble
- Adaptasi & Memory Pooling



A Broad Ensemble Learning System for Drifting Stream Classification

Analisis Hasil & Kesimpulan:

- **Akurasi & Ranking SOTA Terbaik**: Meraih rata-rata akurasi *prequential* **83,59%** (peningkatan **+18,59%** dibanding 10 *baseline*) dan menempati **Peringkat #1** (*average rank* 3,20).
- **Signifikan secara Statistik**: Uji *Friedman* & *Bonferroni-Dunn* membuktikan BELS unggul signifikan secara statistik atas 6 algoritma SOTA (*KUE, OzaADWIN, GOOWE, DWM, HAT, SAM-kNN*).
- **Skalabilitas Tinggi (Feature-Agnostic)**: Rata-rata waktu pemrosesan **625,63 cs / 1.000 sampel**. Komputasi tidak membengkak pada dimensi fitur tinggi (dataset *Email* 913 fitur: BELS **120 cs** vs ARF **28.165 cs**).
- **Tangguh pada Stream Tidak Seimbang**: Meraih performa skor *Kappa* terbaik yang sejajar dengan algoritma khusus *imbalance* (ROSE).
- **Dampak Arsitektur (Ablasi)**: Desain *mini-chunk* dan *output layer ensemble* meningkatkan akurasi model *Broad Learning System* (BLS) asli sebesar **+41,44%**.

Kontribusi Penelitian:

Mengusulkan kerangka BELS berbasis *mini-chunk* (Sc < 50) dengan *passive ensemble* pada *output layer* jaring saraf ringan yang mengungguli 10 metode *State-of-the-Art* (SOTA).

Gap Penelitian:

BELS merupakan metode *passive ensemble* yang terikat kaku (*tightly-coupled*) pada arsitektur *Broad Learning System* (BLS) serta tidak memiliki mekanisme aktif untuk mendeteksi tingkat keparahan *drift* maupun menyaring data

TS-DM: Segmentasi Waktu untuk Concept Drift

Wang, Lu, Liu & Zhang · IEEE Transactions on Cybernetics, vol. 54 no. 10, 2024

Objek

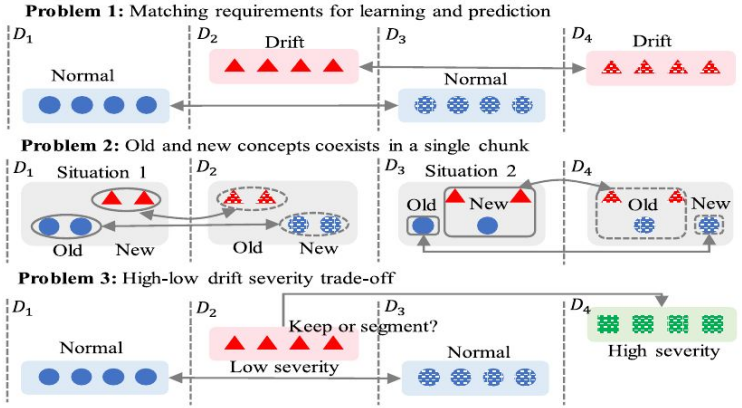
Artikel ini membahas pembelajaran data stream yang distribusinya berubah dari waktu ke waktu (concept drift), mis. cuaca, minat pengguna, pasar saham.

Masalah

Retrain di tiap chunk membuang atau menyimpan data secara buta. Tantangan: kecocokan data dan prediksi, konsep lama-baru dalam satu chunk, trade-off severity drift.

Tujuan

Memilah dan memilih data stream secara fleksibel agar model tetap akurat dan robust pada berbagai tipe dan tingkat drift.



Gbr. 2 paper: tiga masalah segmentasi pada data stream

Kontribusi

1 Segmentasi chunk
Memisah chunk menjadi set normal dan drift

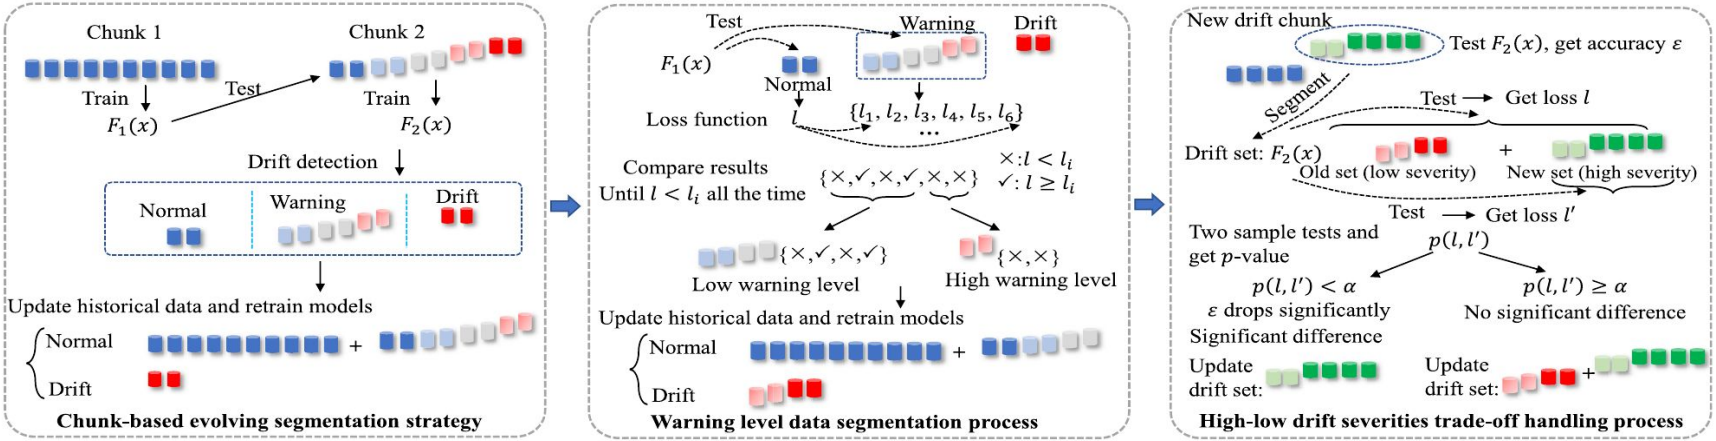
2 CES
Titik potong normal vs drift di dalam satu chunk

3 CES-W
Segmentasi data level warning (rendah vs tinggi)

4 Trade-off drift
Simpan atau buang data lama sesuai severity

Tahapan dan Metode TS-DM

Model dasar: Gradient Boosting (F1 untuk data normal, F2 untuk data drift)



Gbr. 3 paper: prosedur CES, segmentasi level warning, dan penanganan trade-off severity

1 Segmentasi chunk

Latih F1 (normal) dan F2 (drift), pilih model dengan akurasi lebih tinggi, simpan μ = 1000 sampel terbaru.

2 CES

DDM mendeteksi titik warning (iw) dan drift (id) dalam satu chunk. Data sebelum id masuk set normal, sisanya masuk set drift.

3 CES-W

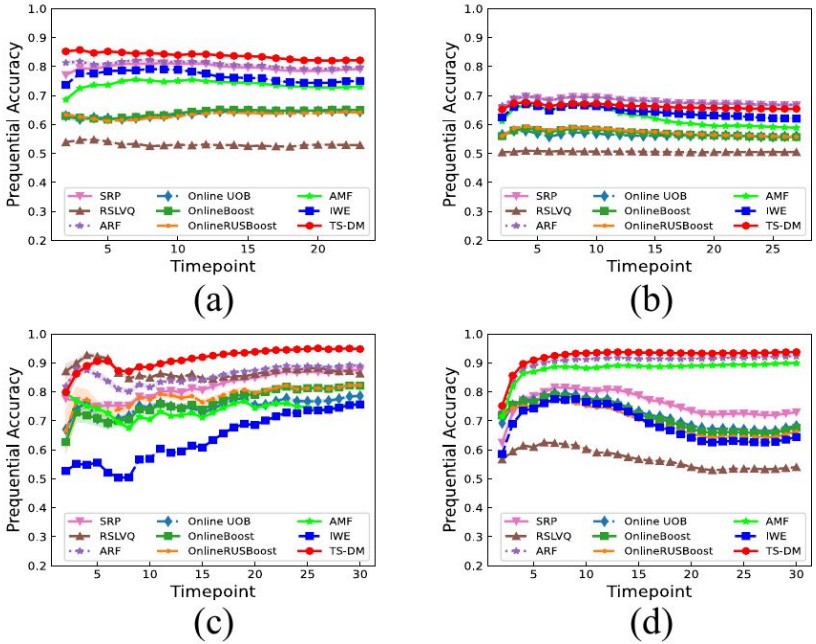
Loss tiap sampel warning dibandingkan dengan loss data normal. Low-warning ke set normal, high-warning ke set drift.

4 Trade-off drift

Uji K-S ($p < 0{,}01$) dan penurunan akurasi lebih dari β (β = 0,6) menentukan apakah data lama dibuang.

Hasil: Unggul Rata-rata dan Lebih Robust

Eksperimen pada data sintetis (MOA, River) dan data nyata; pembanding: SRP, RSLVQ, ARF, UOB, OB, RUSB, AMF, IWE



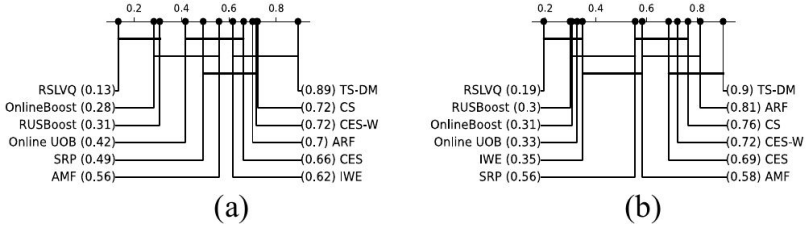
Gbr. 6 paper: akurasi prequential pada Electricity, Airline, EEG, Covertype (TS-DM = garis merah)

73,65%
Rata-rata akurasi
peringkat 2,1

66,69%
Rata-rata F1
peringkat 1,5

55,17%
Rata-rata MCC
peringkat 2,0

Skor rata-rata pada data nyata



Gbr. 7 paper: diagram CD (kiri sintetis, kanan data nyata)

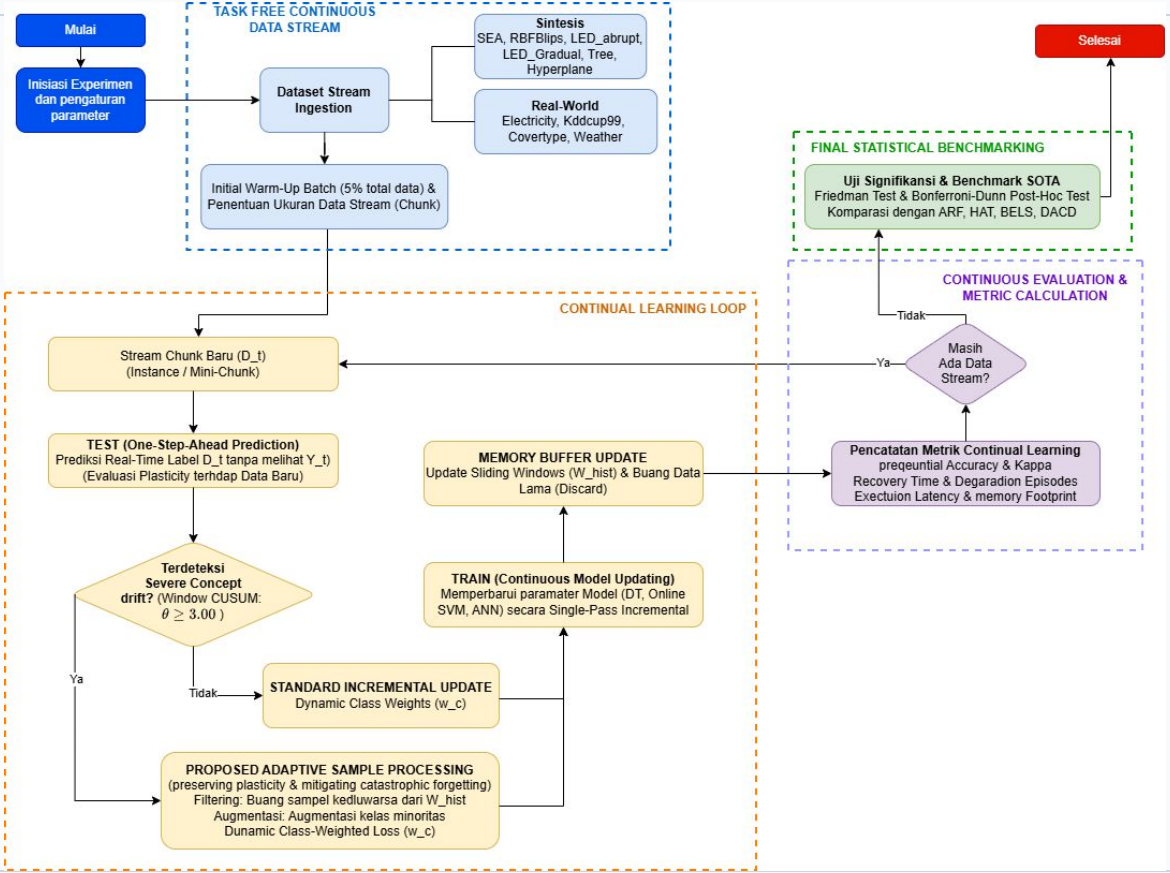
- Uji Friedman signifikan ($p < 0,05$) terhadap 7 dari 8 pembanding pada data nyata (kecuali ARF pada akurasi).
- AMF dan IWE kuat pada drift ringan (RBF, HYP), lemah pada drift berat (AGRa).
- Sliding window tidak lebih baik; waktu komputasi masih di atas AMF dan IWE.

Sumber: Wang et al., IEEE Trans. Cybern. 54(10), 2024 — Tabel III–VI, Gbr. 6–8

Research Gap

No	Artikel / Penelitian	Fokus Concept Drift dalam Skenario Parah (Severe / Multi-Class Locality)	Pengolahan Sampel Adaptif	Framework Hibrida (deteksi severe concept drift + adaptif sample processing)	Kontrol Kompleksitas Dinamis	Penanganan Degradasi Model
1	A comprehensive analysis of concept drift locality in data streams	Ya	Tidak	Tidak	Tidak	Ya
2	Anticipating to Change: A Proactive Approach for Concept Drift Adaptation in Data Streams	Ya	Tidak	Tidak	Tidak	Ya
3	DACD: a dynamic adaptive concept drift learning method for streaming data	Ya	Ya	Tidak	Tidak	Ya
4	A Broad Ensemble Learning System for Drifting Stream Classification	Ya	Ya	Tidak	Tidak	Ya
5	Regularised feed forward neural networks for streamed data classification	Ya	Tidak	Tidak	Ya	Ya
6	Penelitian Usulan	Ya	Ya	Ya	Ya	Ya

Tahapan Penelitian



Dataset

Dataset yang akan digunakan terbagi atas 2 yaitu

1. **Dataset Simulasi**

   Dataset Simulasi merupakan data buatan yang dihasilkan menggunakan aturan, model matematika, atau algoritma dengan pola tertentu. Dataset ini digenerate menggunakan Massive Online Analysis (MOA), yaitu sebuah framework untuk membuat simulasi data.

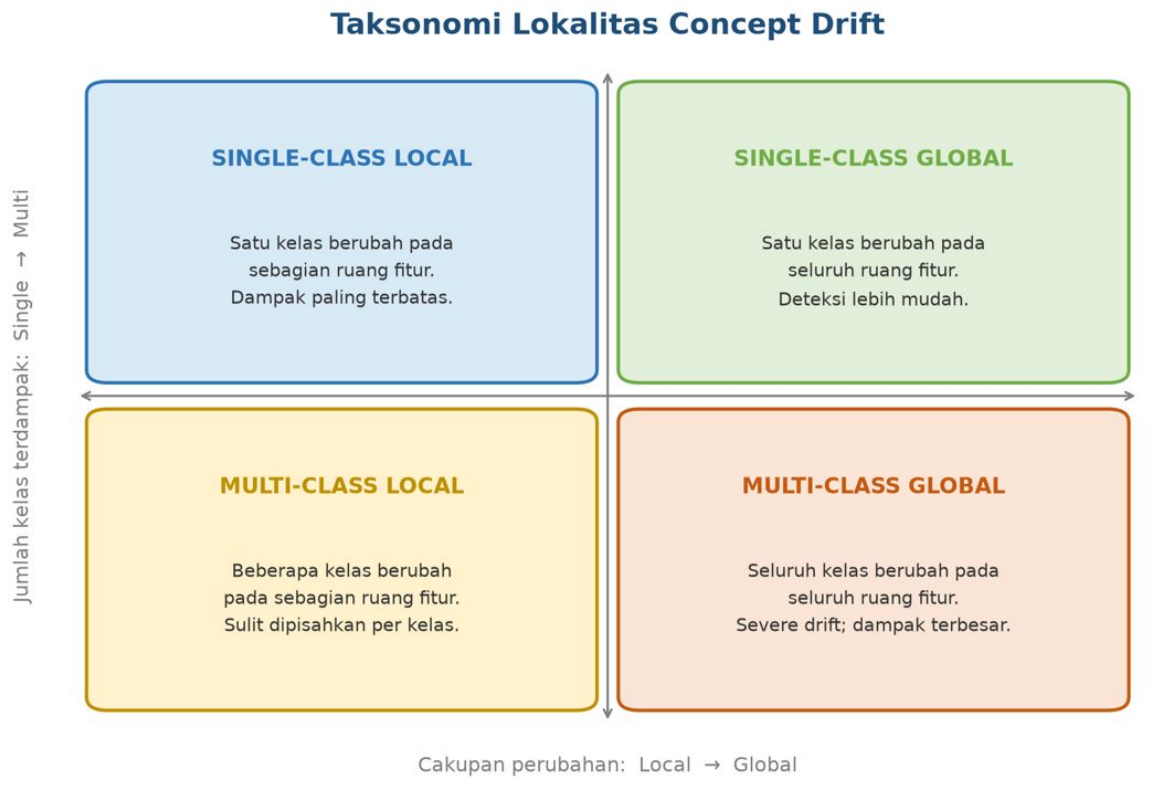
   a. Sea: Berisi data simulasi dengan gradual drift pada 25%, 50%, dan 75% data stream. Berisi 100.000 sampel, 3 fitur, 2 kelas.
   b. RBFBlips: Berisi data simulasi dengan abrupt drift pada 25%, 50%, dan 75% data stream. Berisi 100.000 sampel, 20 fitur, 4 kelas.
   c. LED_abrupt: Berisi data simulasi dengan abrupt drift khusus pada titik 50% data stream. Berisi 100.000 sampel, 24 fitur, 10 kelas.
   d. LED_gradual: Berisi data simulasi dengan gradual drift pada 25%, 50%, dan 75% data stream. Berisi 100.000 sampel, 24 fitur, 10 kelas.
   e. Tree: Berisi data simulasi dengan abrupt drift pada 25%, 50%, dan 75% data stream. Berisi 100.000 sampel, 30 fitur, 10 kelas.
   f. Hyperplane: Berisi data simulasi dengan incremental drift. Berisi 100.000 sampel, 10 fitur, 2 kelas.

2. **Dataset Real World**

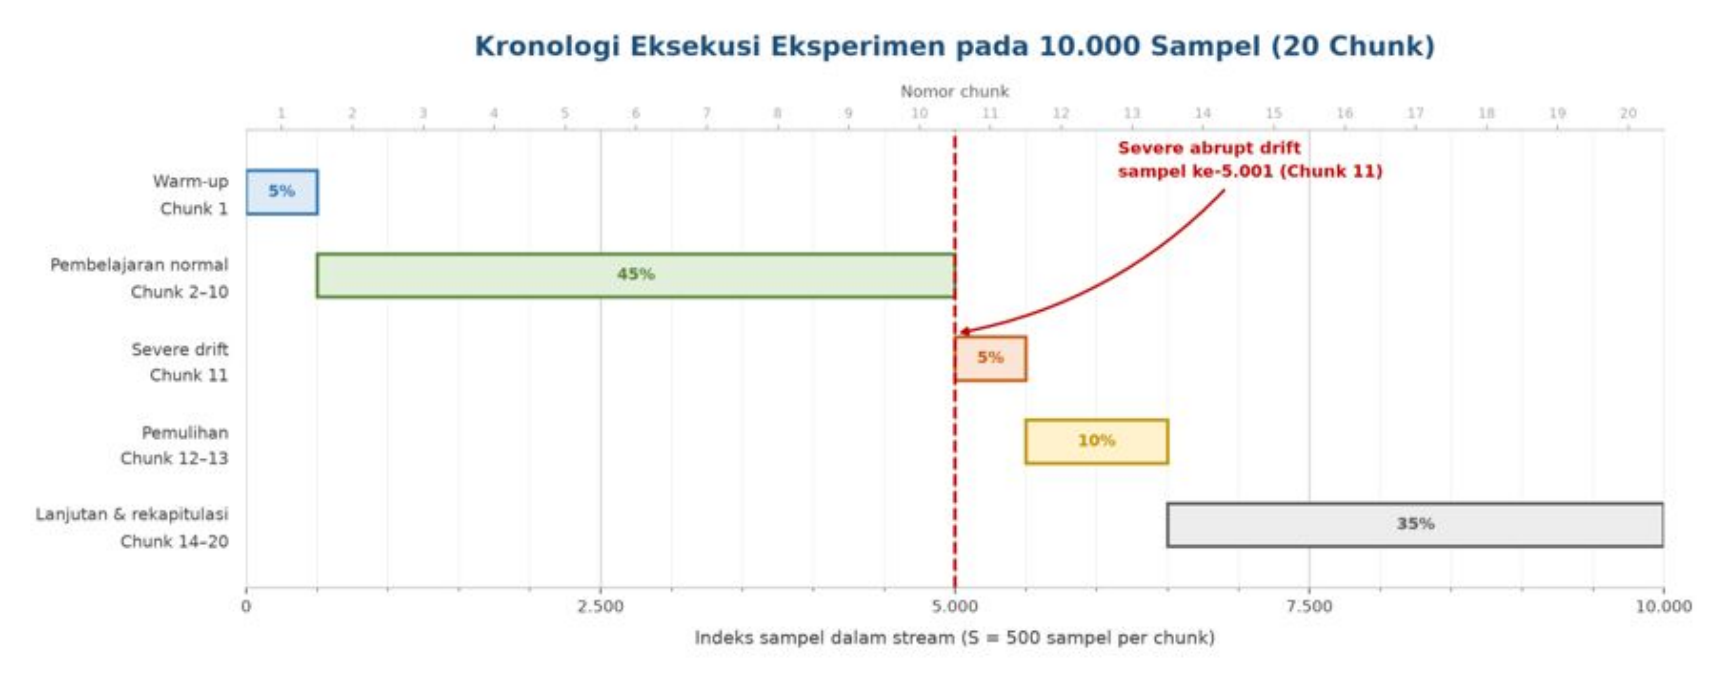
   Dataset Real World merupakan data hasil pengamatan atau pengukuran langsung di dunia nyata.

   a. Electricity: Berisi data pola konsumsi listrik. Berisi 45.300 sampel, 6 fitur, 2 kelas. URL DATASET
   b. Kddcup99: Berisi data untuk deteksi intrusi jaringan. Berisi 494.000 sampel, 41 fitur, 23 kelas. URL DATASET
   c. Covertype: Berisi data klasifikasi jenis tutupan hutan berdasarkan atribut seperti elevasi, kemiringan, dan jenis tanah. Berisi 581.012 sampel, 54 fitur, 7 kelas. URL DATASET
   d. Weather: Berisi data perkiraan cuaca. Berisi 95.100 sampel, 9 fitur, 3 kelas. URL DATASET

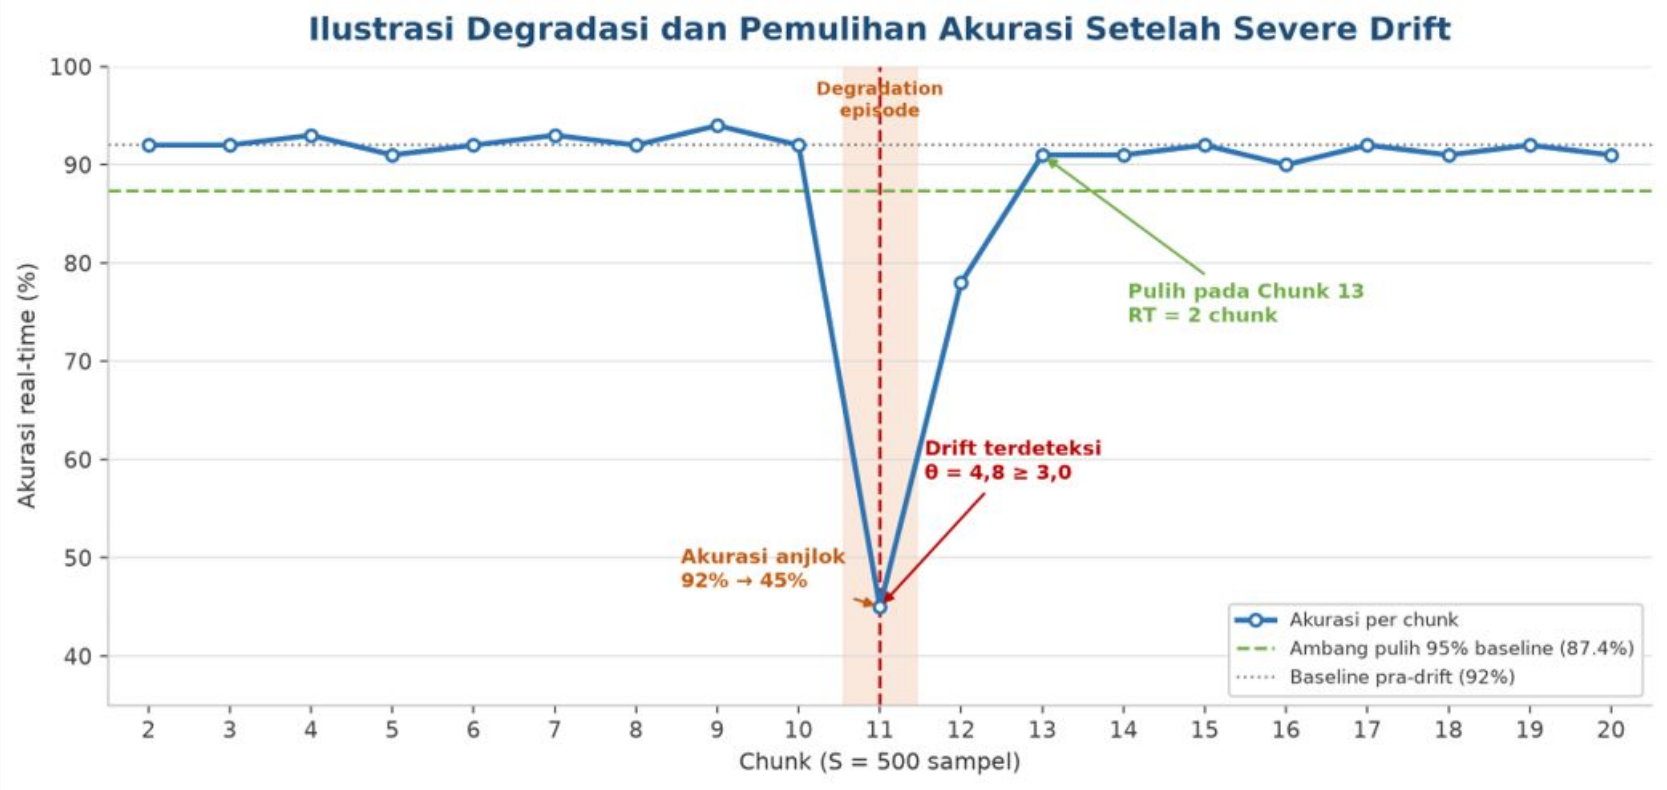
Skenario Uji Coba



Skenario Uji Coba



Skenario Uji Coba



Skenario Uji Coba

