

MULTI-VIEW ENSEMBLE FEATURE SELECTION FOR INTERPRETABLE DIABETES DETECTION: A COMPARATIVE STUDY OF MACHINE LEARNING MODELS

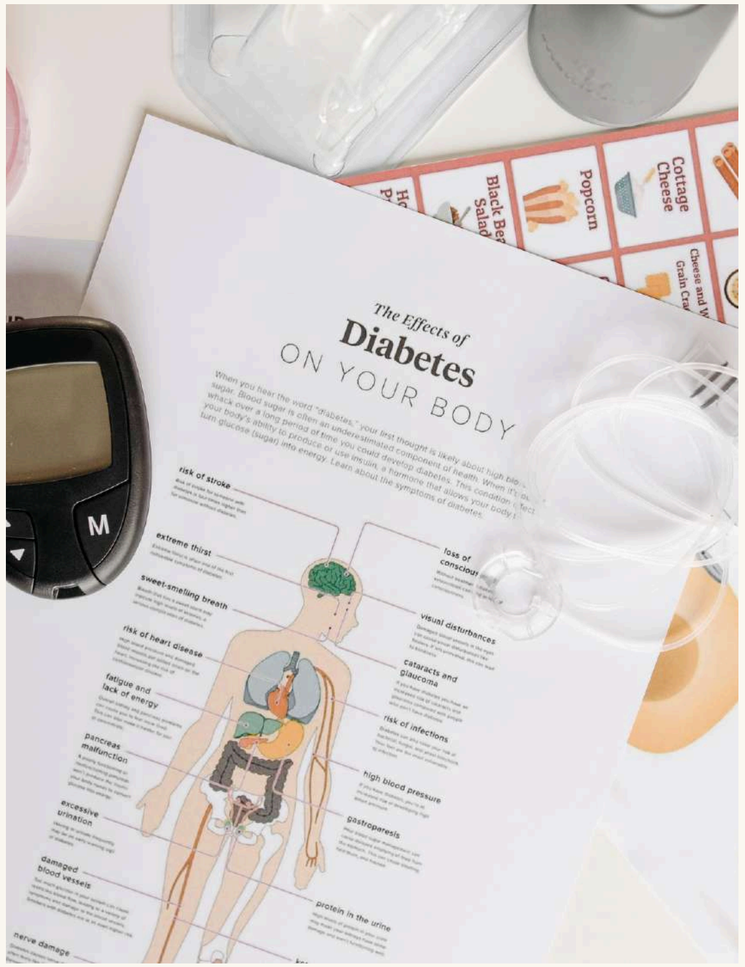
Muhammad Zuama Al Amin
6025251004

Galuh Try Langgeng Sadewa
6025251046

Miftah Furqaanul Haq
6025251038

Ryan Gading Abdullah
6025251052

Introduction



Mengapa Diabetes?

Beban global dan ekonomi yang besar

- 589 juta dewasa (11,1%) hidup dengan diabetes pada 2024, diproyeksikan 853 juta pada 2050 (Genitsaridi et al., 2025)
- Biaya di AS 2022: 412,9 miliar USD (Parker et al., 2024)

Deteksi dini berbasis data dibutuhkan

- Lebih dari 4 dari 10 dewasa dengan diabetes belum terdiagnosis (Genitsaridi et al., 2025)
- BRFSS 2022-2024 (>1,3 juta baris, 326-345 variabel, kelas tidak seimbang) sesuai untuk seleksi fitur (Rahman et al., 2025)

Risiko diabetes multifaktor, fitur penting belum konsisten

- Prediksi diabetes melibatkan faktor klinis, laboratorium, gaya hidup, demografi, dan riwayat medis (Chen et al., 2026)
- Fitur terpilih berbeda antar studi dan dataset (mis. usia, BMI, tekanan darah, glukosa, poliuria), dan seleksi fitur tidak selalu menaikkan akurasi (Kaliappan et al., 2024)
- Studi diabetes yang ada umumnya belum mengukur stabilitas fitur terpilih (Chen et al., 2026; Kaliappan et al., 2024; Zeebaree et al., 2026)



PROBLEM

HIGH DIMENSIONALITY AND COMPUTATIONAL COST

Jumlah fitur yang berlebihan meningkatkan kompleksitas model, waktu pelatihan, dan kebutuhan komputasi.

IRRELEVANT AND REDUNDANT FEATURES

Fitur yang tidak relevan atau saling berkorelasi dapat mengurangi kualitas representasi data dan meningkatkan risiko overfitting.

LIMITATIONS OF SINGLE FEATURE SELECTION METHODS

Penggunaan satu metode seleksi fitur dapat menghasilkan fitur terpilih yang bias terhadap kriteria tertentu dan belum tentu optimal untuk klasifikasi diabetes.

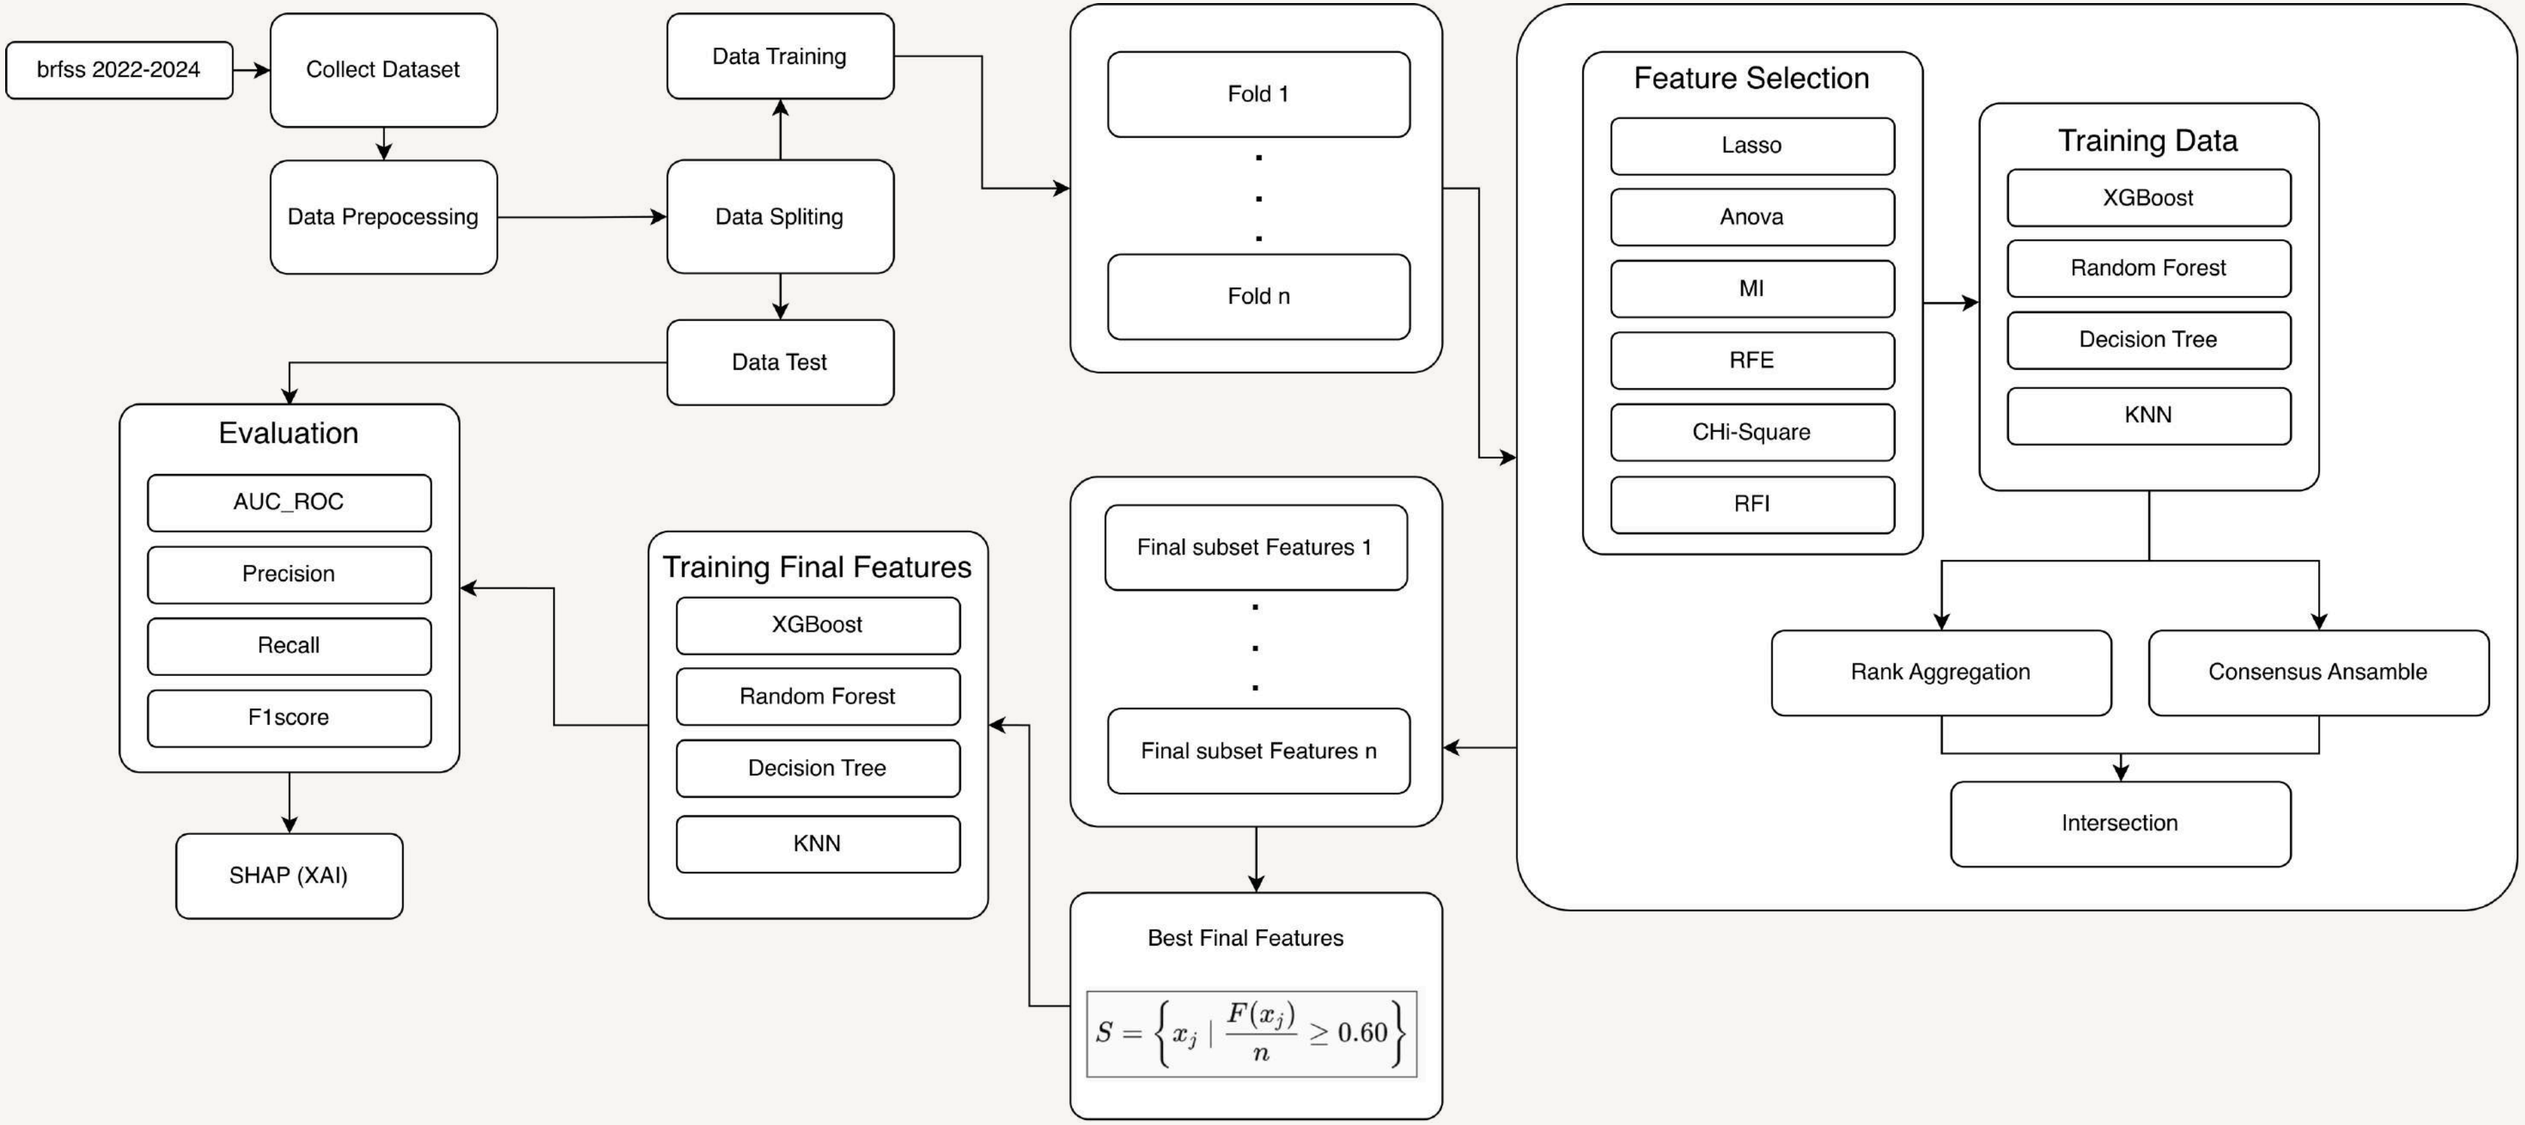
ACCURACY–EFFICIENCY TRADE-OFF AND CLASS IMBALANCE

Pengurangan fitur perlu mempertahankan performa klasifikasi, khususnya dalam mendeteksi pasien diabetes secara tepat pada data yang tidak seimbang dan meminimalkan false negatives.

Gaps and Position

Paper	Dataset	Ensemble Feature Selection	Explainable AI	Ensemble Model	Feature Stability	Domain	Quartile
Kaliappan et al. (2024)	4 dataset diabetes Kaggle (8–17 atribut)	✓	✓	✓	✗	Diabetes	Q1
Chen J et al. (2026), Digital Health	1.879 pasien, 46 fitur	✓	✓	✓	✗	Diabetes	Q1
Zeebaree et al. (2026)	PIMA dan Frankfurt	✓	✗	✓	✗	Diabetes	Q2
Battistella et al. (2024)	4 dataset biomedis (mis. rheumatoid arthritis)	✓	✗	✗	✓	Biomedis (bukan diabetes)	Q1
Jiang et al. (2024)	CDC BRFSS 2021	✗	✓	✓	✗	Diabetes	Q1
Natarajan et al. (2025)	PIMA Diabetes Dataset	✓	✗	✓	✗	Diabetes	Q1
This Research	CDC BRFSS 2022-2024	✓	✓	✓	✓	Diabetes	-

Proposed Framework



Penjelasan Proposed Framewrok



1. Training data menggunkan 6 metode FS
2. Pemilihan kandidat FS terbaik berdasarkan n>mean PR-AUC dari 4 model algoritma
3. Setiap features dari metode FS terbaik diranking menggunakan 2 metode :
   - Rank Agregation
   - Consensus Ensemble
4. Feature yang berada pada irisan RA dan CE masuk ke dalam final features n
5. Proses 1 - 4 berulang sesuai dengan jumlah fold dan pengulangannya
6. Best final features dipilih dari final features 1 - n yang tingkat kemunculannya lebih dari 60%
7. Best final features digunakan pada data test dengan 4 metriks evaluasi dan dijelaskan menggunakan SHAP

Dataset



BRFSS tahun 2022-2024

- Dataset BRFSS 2024: Terdiri dari 345 fitur (dengan 457.670 baris data).
- Dataset BRFSS 2023: Terdiri dari 345 fitur (dengan 433.323 baris data).
- Dataset BRFSS 2022: Terdiri dari 326 fitur (dengan 445.132 baris data).
- Fitur Diabetes dijadikan sebagai label

Data Prepocessing



Prepocessing Process

- Penyatuan nama fitur: menyeragamkan nama variabel BRFSS tahun 2022-2024 agar bisa digabung.
- Penghapusan fitur dengan missing value tinggi: membuang fitur dengan missing value > 15%.
- Penghapusan fitur redundan: membuang fitur yang menyimpan informasi yang sama atau duplikat.
- Penghapusan fitur berkorelasi tinggi: membuang salah satu dari pasangan fitur dengan korelasi > 0,7.
- Penghapusan baris: membuang baris yang masih memiliki missing value.
- Pembagian data: 70% data latih (training) dan 30% data uji (testing).
- Dataset akhir terdiri atas 43 kolom (42 fitur + 1 target), tanpa missing value.

Training Model



Machine Learning

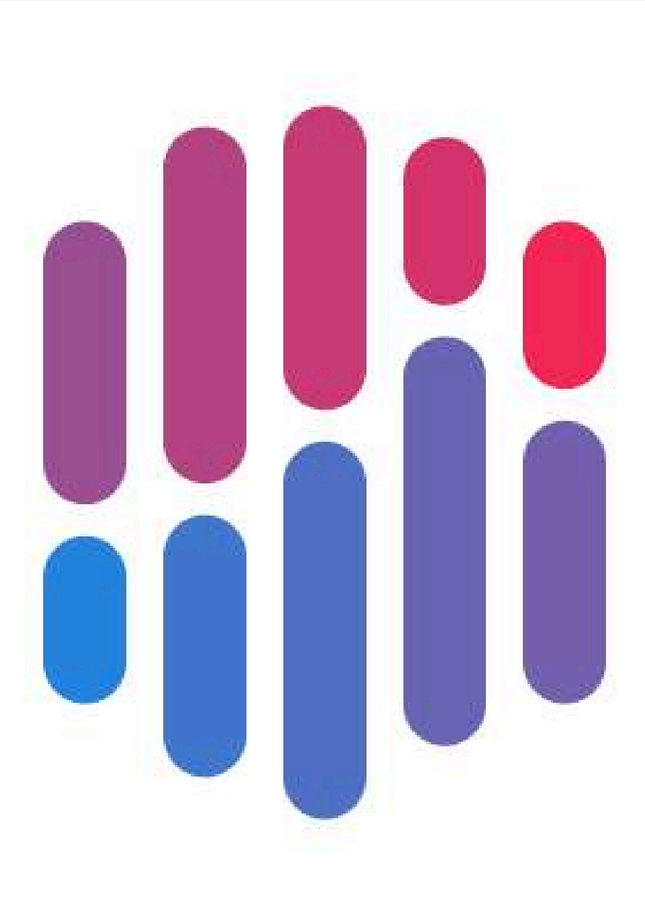
- Ensemble Learning
  - XGboost
  - Random Forest
- Single Learning
  - KNN
  - Decision Tree

Dasar Pemilihan Model

Sumber: Shwartz-Ziv & Armon (2022); Grinsztajn, Oyallon & Varoquaux (2022).

- XGBoost dan model pohon mengungguli deep learning pada data tabular, dengan komputasi >10× lebih cepat.
- Deep learning kalah karena bias terlalu halus, sensitif terhadap fitur tidak informatif, dan rotationally invariant.

Explainable AI (XAI)



SHAP

- Model dengan kinerja terbaik dianalisis lebih lanjut menggunakan SHAP (SHapley Additive exPlanations) untuk mengestimasi kontribusi masing-masing fitur terhadap prediksi.
- SHAP dipilih karena merupakan salah satu metode interpretabilitas yang umum digunakan.

Daftar Pustaka



1. Genitsaridi, I., et al. (2025). Lancet Diabetes Endocrinol. https://pubmed.ncbi.nlm.nih.gov/41412135/
2. Parker, E. D., et al. (2024). Diabetes Care, 47(1). https://pubmed.ncbi.nlm.nih.gov/37909353/
3. Rahman, et al. (2025). Diagnostics, 15(20), 2622. https://doi.org/10.3390/diagnostics15202622
4. Kaliappan, J., et al. (2024). https://doi.org/10.3389/frai.2024.1421751
5. Chen J et al. (2026). https://doi.org/10.1177/20552076261453207
6. Majeed, D. A., et al. (2026). https://doi.org/10.3390/bioengineering13040480
7. Battistella, E., Ghiassian, D., & Barabási, A.-L. (2024). https://doi.org/10.1093/bioinformatics/btae341

THANK YOU

